已完成 Dense 模型预测实验阶段汇总

数据截止：2026-09-29 19:13。本报告纳入本轮已完成真机采集、ML 训练、独立测试和端到端回放的 10 个 dense checkpoint，包含 14B-1M 和 70B-AWQ。32B 本轮尚未完成，不纳入结果；两个 MoE 模型不在本报告范围内。

1. 实验环境与采样设置

项目	9 月 18 日实验	本轮 9 月 28—29 日实验
GPU	A100 80GB PCIe，单卡	同一台 A100 80GB PCIe，单卡
环境	conda hbf-cxl；Python 3.10.21	相同
SGLang 源码	PR #33824 合并源码，59799a368793b9f795baf59b067233a65ad8e38e	相同 revision
SGLang 包元数据	0.0.0；不是正式 0.5.18 wheel	相同
sglang-kernel	SM80 兼容 minimal-stage-v4；包版本 0.4.6.post1+cu129	相同 stage；运行版本 0.4.6.post1
Torch / CUDA 运行库	2.9.1+cu126 / 12.6	相同
驱动	535.230.02；nvidia-smi 报告 CUDA 12.2	相同本机；Torch CUDA 版本按上一行记录
ML	HistGradientBoostingRegressor，p50 损失；scikit-learn 1.6.1	相同算法和预定损失
服务参数	TP=1；context=2048；最大运行请求=32；chunked prefill=512	相同
CUDA graph / overlap	均关闭	均关闭
dtype / KV dtype 启动参数	auto / auto	auto / auto；特殊模型见下表说明
训练预算 / 模型	320 请求，1 类负载，5 轮	800 请求，3 类负载，5 轮
独立测试预算 / 模型	320 请求，1 类负载，5 轮	1280 请求，5 类负载，5 轮
训练 / 测试 seed	20260918—20260922 / 20261018—20261022	202609280—202609284 / 202609380—202609384
AIC	0.10.0，Silicon 本机表，已完成	新算子表与对照尚未完成；本文仅列历史 AIC 数据

单步实测为同步后的 Scheduler.run_batch 墙钟时延，不是纯 GPU 算子时间。端到端指标来自原生 CUDA 服务与 CPU 模拟器的配对回放。模拟器使用实测请求的 token ID、实际输出长度、到达时间和 KV 容量。

本轮每个模型的负载如下；长度是采样上限，并非每个请求的固定长度。random_range_ratio=0；长负载直接发送 token ID，其余负载先解码为文本再由服务编码。

负载简称	输入 / 输出上限（token）	到达方式	每轮请求	训练请求合计	独立测试合计
短延迟	128 / 64	1 请求/s	32	0	160
延迟	256 / 128	1 请求/s	32	160	160

负载简称	输入 / 输出上限（token）	到达方式	每轮请求	训练请求合计	独立测试合计
服务	1024 / 256	4 请求/s	64	320	320
饱和	1024 / 256	一次送入	64	320	320
长饱和	1536 / 384	一次送入	64	0	320

2. 模型配置与数据量

10 个模型共采集 8000 个训练请求、12800 个独立测试请求，分别产生 98127、164241 条单步时延。逐模型检查中，训练与测试的请求 ID、完整输入 token 序列交集均为 0；训练集内部有重复输入，不能将请求数等同于不同 prompt 数。

Checkpoint	图表简称	Attention / 页大小（token）	显存比例：旧 → 新	训练时延条数	测试时延条数
Qwen3-0.6B	Q3-0.6B	triton / 1	0.20 → 0.65	11533	19080
Qwen2.5-3B-Instruct	Q2.5-3B	triton / 1	0.30 → 0.8	10557	17628
llama-2-7b	Llama2-7B	triton / 1	0.72 → 0.72	11532	18500
Mistral-7B-Instruct-v0.2	Mistral-7B	triton / 1	0.35 → 0.35	11319	18306
Qwen2.5-7B-Instruct	Q2.5-7B	triton / 1	0.35 → 0.35	11598	19018
Qwen3-8B	Q3-8B	triton / 1	0.42 → 0.42	10328	17291
Qwen2.5-14B-Instruct	Q2.5-14B	triton / 1	0.60 → 0.60	9073	15701
Qwen2.5-14B-Instruct-1M	Q2.5-14B-1M	dual_chunk_flash_attn / 256	0.60 → 0.60	5862	9974
Qwen3-14B	Q3-14B	triton / 1	0.60 → 0.60	9256	16069
Meta-Llama-3.1-70B-Instruct-AWQ	Llama3.1-70B-AWQ	triton / 1	0.80 → 0.80	7069	12674

14B-1M 使用 dual_chunk_flash_attn、页大小 256，但本次 context 仍为 2048，不是百万 token 上下文实验。70B-AWQ 的原生日志确认使用 awq_marlin，KV 为 float16；它不能与同参数量 BF16 模型视为相同计算配置。

3. 本轮 ML 单步预测结果

总体统计合并五类测试负载的全部 batch，按 batch 数加权。下表时延单位均为 ms，斜线左侧为实测、右侧为预测；误差为逐 batch MAPE。

模型	总体实测 / 预测	总体 MAPE	Prefill 实测 / 预测	Prefill MAPE	Decode 实测 / 预测	Decode MAPE
Q3-0.6B	25.97 / 25.88	6.21%	25.34 / 24.58	4.59%	26.04 / 26.01	6.38%
Q2.5-3B	31.96 / 31.25	4.55%	30.81 / 30.14	3.33%	32.08 / 31.37	4.69%
Llama2-7B	28.37 / 27.49	3.84%	35.39 / 35.22	2.38%	27.62 / 26.67	4.00%
Mistral-7B	29.03 / 28.60	5.42%	36.45 / 36.19	2.86%	28.23 / 27.79	5.70%
Q2.5-7B	26.51 / 25.93	6.04%	34.24 / 33.95	3.57%	25.71 / 25.11	6.29%

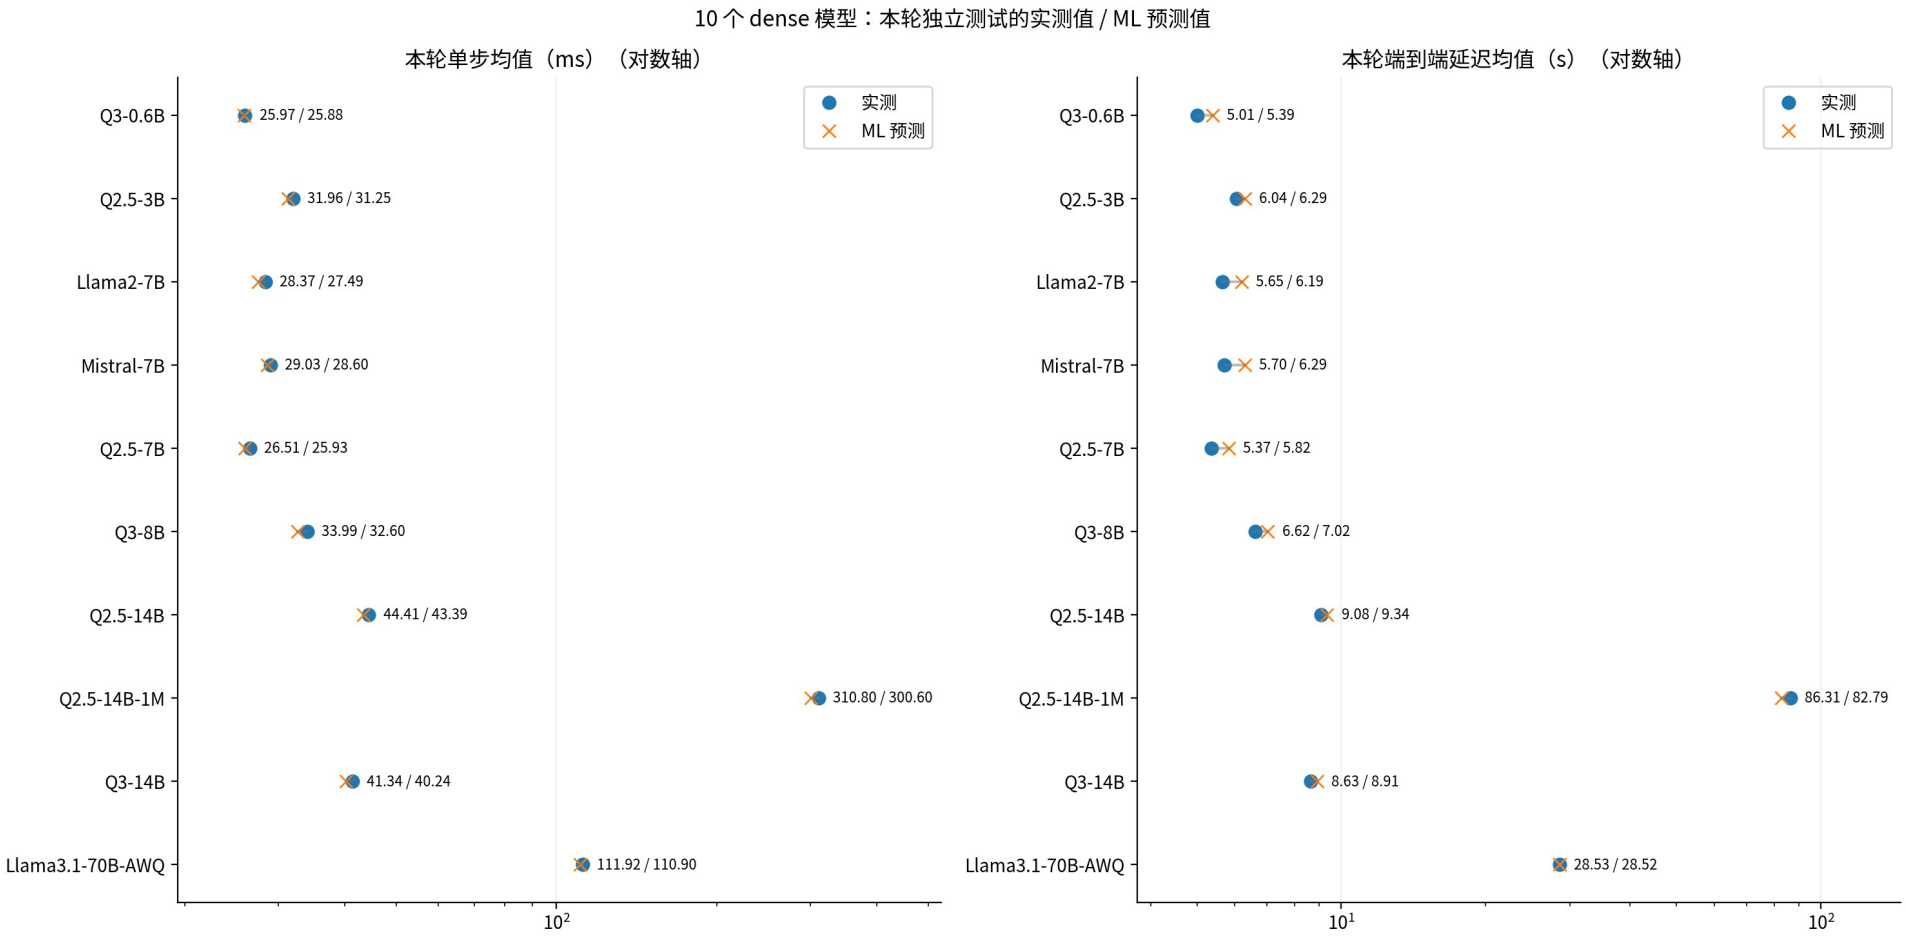
模型	总体实测 / 预测	总体 MAPE	Prefill 实测 / 预测	Prefill MAPE	Decode 实测 / 预测	Decode MAPE
Q3-8B	33.99 / 32.60	4.55%	38.54 / 37.90	2.79%	33.47 / 32.00	4.75%
Q2.5-14B	44.41 / 43.39	3.52%	63.66 / 63.20	2.32%	41.99 / 40.90	3.68%
Q2.5-14B-1M	310.80 / 300.60	12.18%	1212.59 / 1138.23	5.95%	118.25 / 121.74	13.51%
Q3-14B	41.34 / 40.24	6.16%	66.30 / 64.15	3.90%	38.28 / 37.31	6.44%
Llama3.1-70B-AWQ	111.92 / 110.90	4.73%	331.12 / 328.11	2.20%	77.71 / 77.00	5.13%

4. 本轮端到端结果

每个模型包含五类负载 × 五轮，共 25 个配对用例。下表均值和 MAPE 按这 25 个用例等权统计，不是逐请求误差的平均；吞吐采用保存 trace 的实际输入、输出 token 总数。

模型	E2E 实测（s）	E2E 预测（s）	E2E MAPE	吞吐实测（token/s）	吞吐预测（token/s）	吞吐 MAPE
Q3-0.6B	5.008	5.390	10.13%	1671.15	1605.27	3.19%
Q2.5-3B	6.038	6.295	6.33%	1442.03	1418.05	2.30%
Llama2-7B	5.653	6.193	11.21%	1556.88	1470.13	3.94%
Mistral-7B	5.703	6.289	12.02%	1548.22	1450.99	4.41%
Q2.5-7B	5.366	5.823	11.46%	1616.33	1544.33	3.30%
Q3-8B	6.624	7.022	8.41%	1371.75	1315.16	3.00%
Q2.5-14B	9.081	9.341	5.84%	1094.41	1077.54	2.80%
Q2.5-14B-1M	86.307	82.787	5.82%	210.69	215.61	5.73%
Q3-14B	8.630	8.907	7.07%	1163.18	1135.82	2.96%
Llama3.1-70B-AWQ	28.532	28.523	3.18%	464.52	465.16	1.10%
模型	**TTFT 实测（ms）**	**TTFT 预测（ms）**	**TTFT MAPE**	**TPOT 实测（ms）**	**TPOT 预测（ms）**	**TPOT MAPE**
Q3-0.6B	1330.83	1400.24	22.41%	33.91	36.51	9.74%
Q2.5-3B	1603.26	1644.65	19.69%	40.88	42.86	7.08%
Llama2-7B	1683.44	1761.60	12.11%	36.89	41.11	12.08%
Mistral-7B	1708.59	1779.48	13.54%	37.39	42.21	13.45%
Q2.5-7B	1641.51	1669.89	18.80%	34.90	38.93	12.86%
Q3-8B	1926.56	1938.14	17.25%	43.41	47.15	10.12%
Q2.5-14B	2657.05	2789.08	18.98%	60.43	61.47	6.60%
Q2.5-14B-1M	41390.23	39524.95	7.58%	630.97	609.92	6.49%
Q3-14B	2748.36	2720.46	18.91%	55.95	58.30	8.32%
Llama3.1-70B-AWQ	13090.90	11930.68	13.03%	139.42	172.91	21.36%

本轮独立测试：单步与端到端的实测值、预测值



70B-AWQ 的 E2E MAPE 为 3.18%，但 TPOT MAPE 为 21.36%；长饱和负载的 TPOT MAPE 为 45.90%。整体延迟接近不代表首 token 或逐 token 指标都接近。

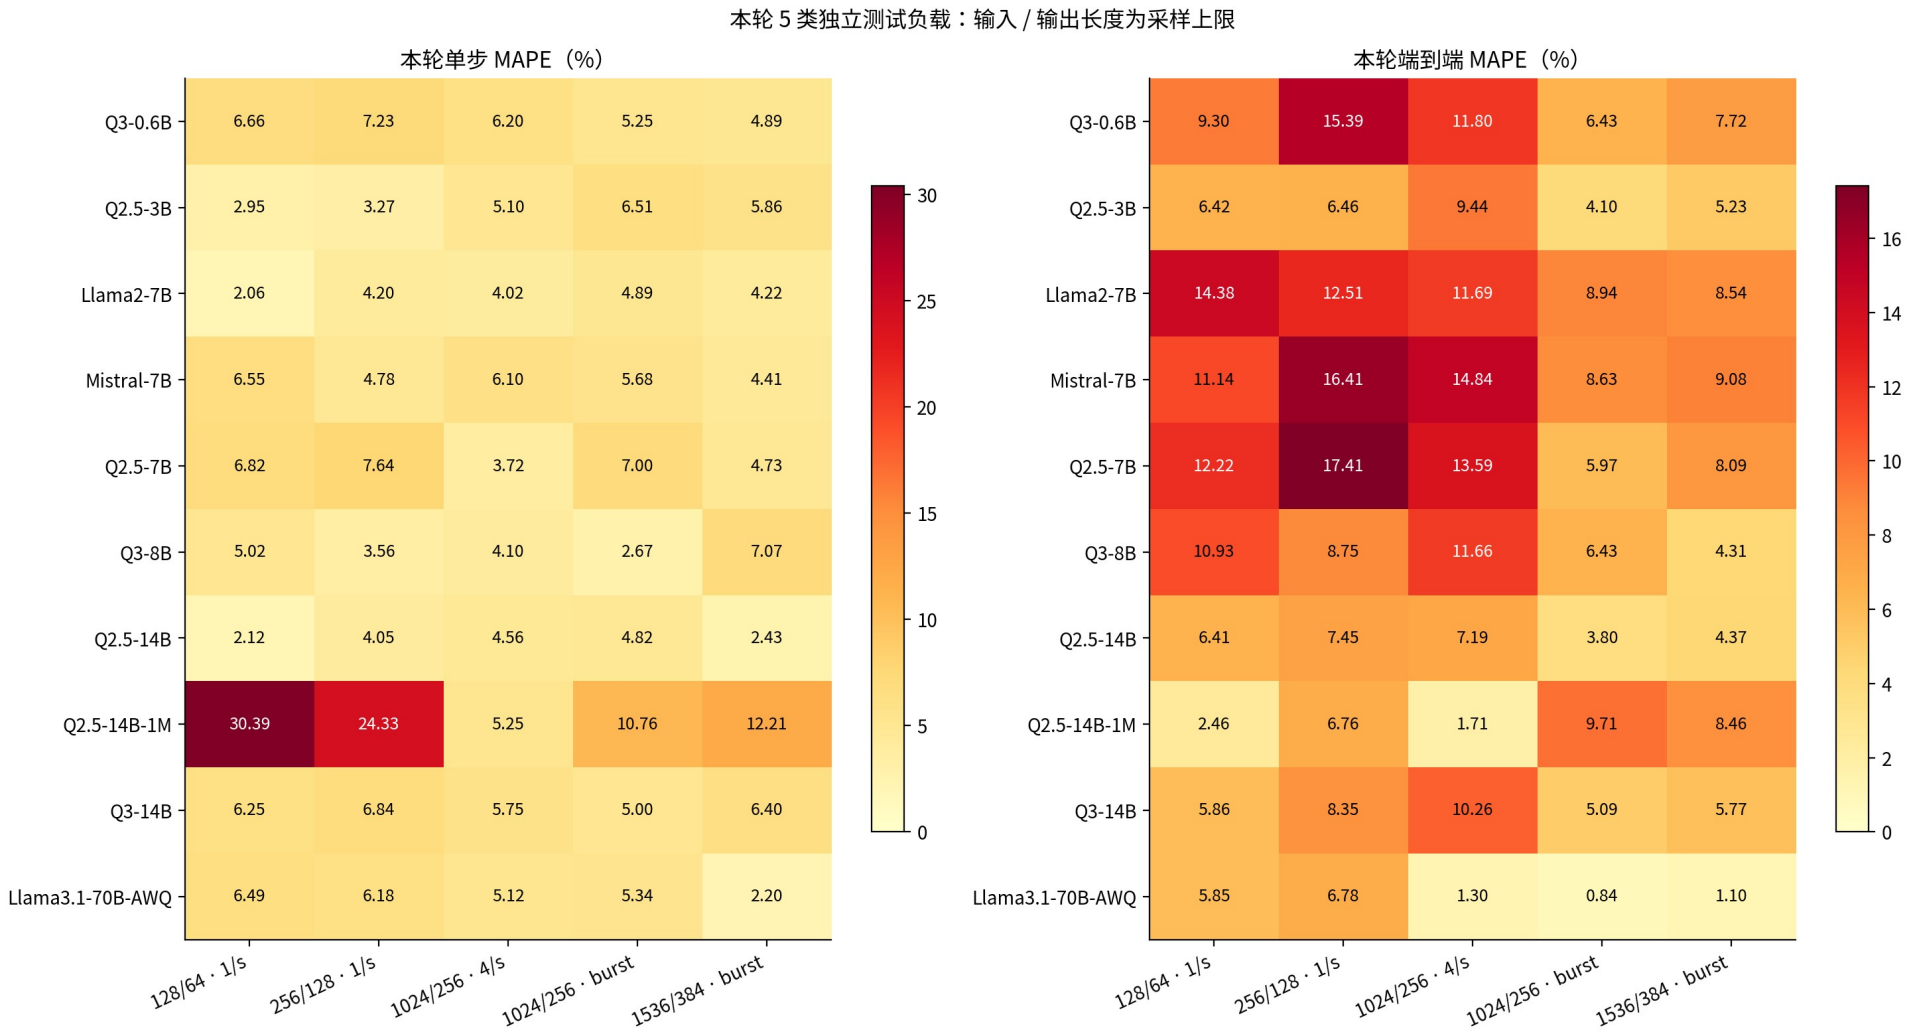
5. 各负载误差

每格依次为“单步 MAPE / E2E MAPE”，单位为 %。各负载均使用独立于训练的测试请求。

模型	短延迟 128/64	延迟 256/128	服务 1024/256	饱和 1024/256	长饱和 1536/384
Q3-0.6B	6.66 / 9.30	7.23 / 15.39	6.20 / 11.80	5.25 / 6.43	4.89 / 7.72

模型	短延迟 128/64	延迟 256/128	服务 1024/256	饱和 1024/256	长饱和 1536/384
Q2.5-3B	2.95 / 6.42	3.27 / 6.46	5.10 / 9.44	6.51 / 4.10	5.86 / 5.23
Llama2-7B	2.06 / 14.38	4.20 / 12.51	4.02 / 11.69	4.89 / 8.94	4.22 / 8.54
Mistral-7B	6.55 / 11.14	4.78 / 16.41	6.10 / 14.84	5.68 / 8.63	4.41 / 9.08
Q2.5-7B	6.82 / 12.22	7.64 / 17.41	3.72 / 13.59	7.00 / 5.97	4.73 / 8.09
Q3-8B	5.02 / 10.93	3.56 / 8.75	4.10 / 11.66	2.67 / 6.43	7.07 / 4.31
Q2.5-14B	2.12 / 6.41	4.05 / 7.45	4.56 / 7.19	4.82 / 3.80	2.43 / 4.37
Q2.5-14B-1M	30.39 / 2.46	24.33 / 6.76	5.25 / 1.71	10.76 / 9.71	12.21 / 8.46
Q3-14B	6.25 / 5.86	6.84 / 8.35	5.75 / 10.26	5.00 / 5.09	6.40 / 5.77
Llama3.1-70B-AWQ	6.49 / 5.85	6.18 / 6.78	5.12 / 1.30	5.34 / 0.84	2.20 / 1.10

本轮五类负载的单步与端到端误差



14B-1M 的短延迟、延迟负载单步误差分别为 30.39%、24.33%，明显高于其服务负载的 5.25%。当前数据说明误差与负载有关，尚不能只凭这一现象确定具体算子原因。

6. 与 9 月 18 日实验的共同负载对比

仅比较双方均有的 1024/256 饱和负载：每模型均为五轮 × 64 请求。两轮 seed、实际请求和训练负载覆盖不同；0.6B、3B 的显存比例也改变。因此下表是历史结果比较，不是仅改变训练样本量的控制实验。“变化”为本轮减旧实验的百分点，负值表示误差下降。

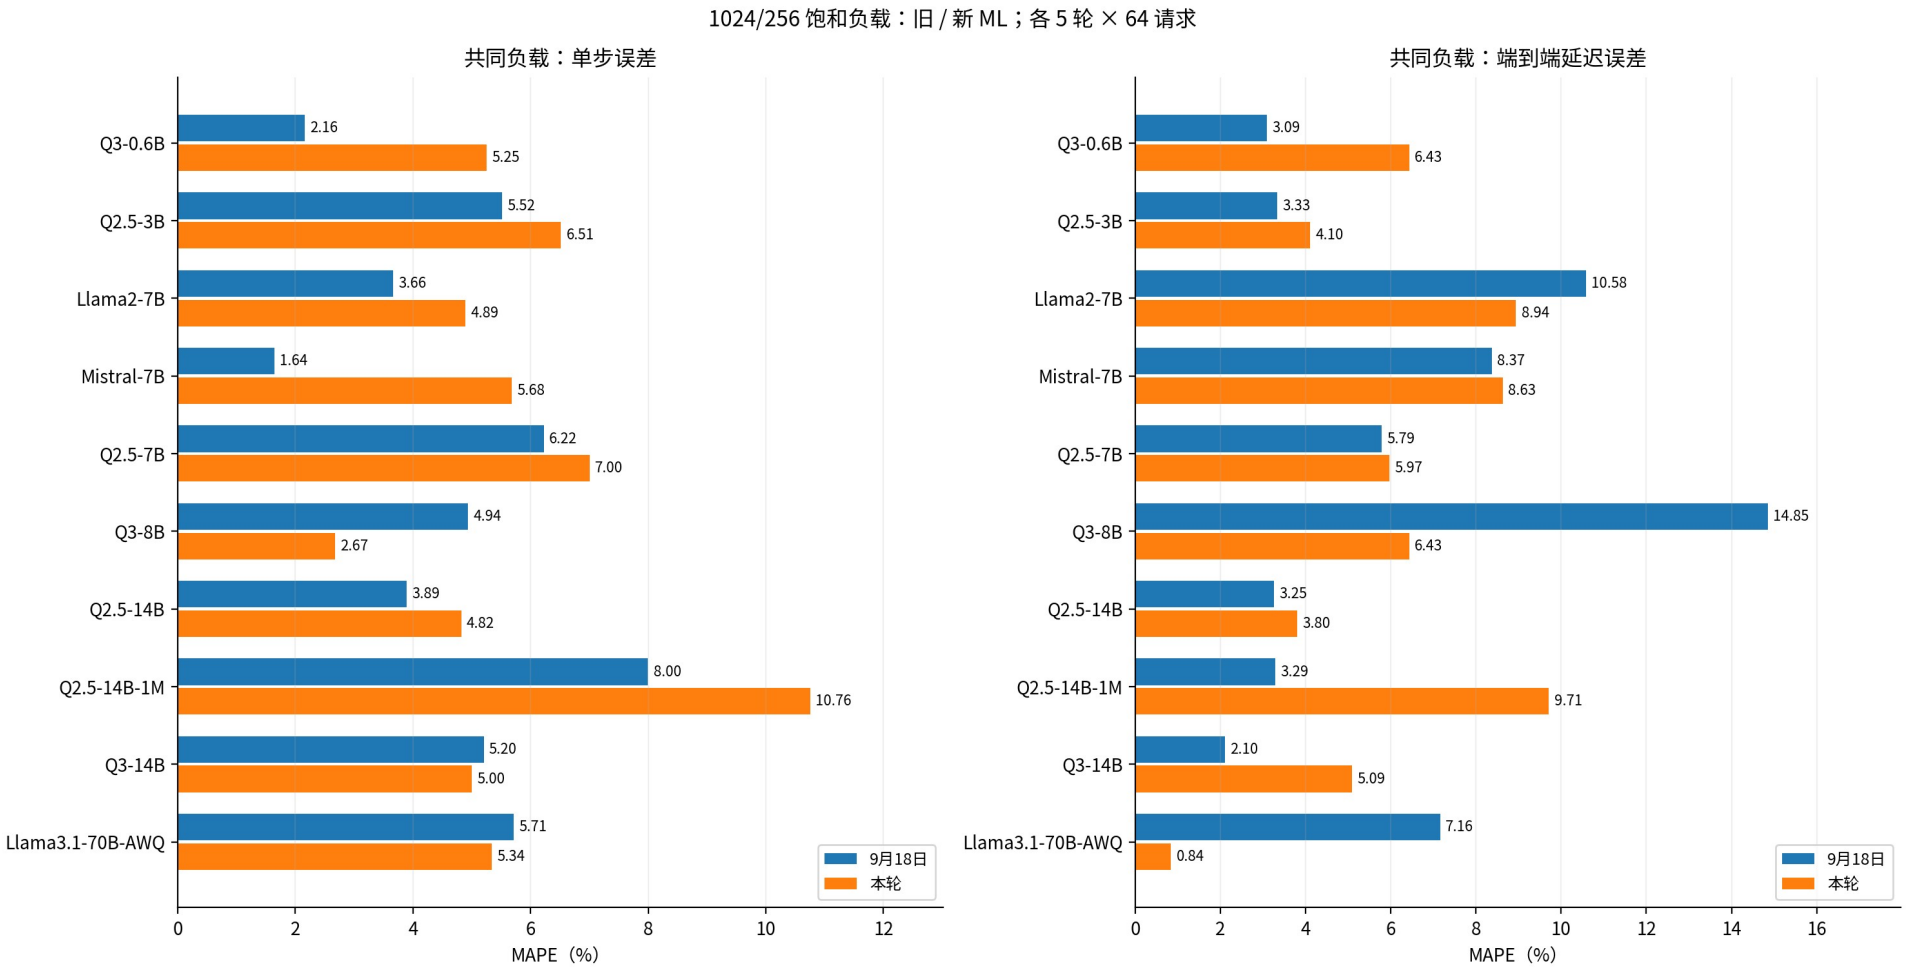
6.1 单步实测、预测与误差

模型	旧实测（ms）	旧预测（ms）	旧 MAPE	本轮实测（ms）	本轮预测（ms）	本轮 MAPE	变化（百分点）
Q3-0.6B	25.04	23.83	2.16%	27.17	25.78	5.25%	3.095
Q2.5-3B	31.05	29.67	5.52%	33.26	31.82	6.51%	0.995
Llama2-7B	28.47	26.79	3.66%	30.39	28.90	4.89%	1.231
Mistral-7B	28.34	27.20	1.64%	30.62	29.87	5.68%	4.034
Q2.5-7B	27.19	25.83	6.22%	28.70	26.96	7.00%	0.778
Q3-8B	33.00	32.68	4.94%	34.27	33.30	2.67%	-2.266
Q2.5-14B	45.12	42.52	3.89%	49.08	46.38	4.82%	0.932
Q2.5-14B-1M	280.96	292.65	8.00%	332.28	303.52	10.76%	2.760
Q3-14B	41.83	38.94	5.20%	44.84	42.80	5.00%	-0.199
Llama3.1-70B-AWQ	121.06	120.77	5.71%	125.67	127.07	5.34%	-0.370

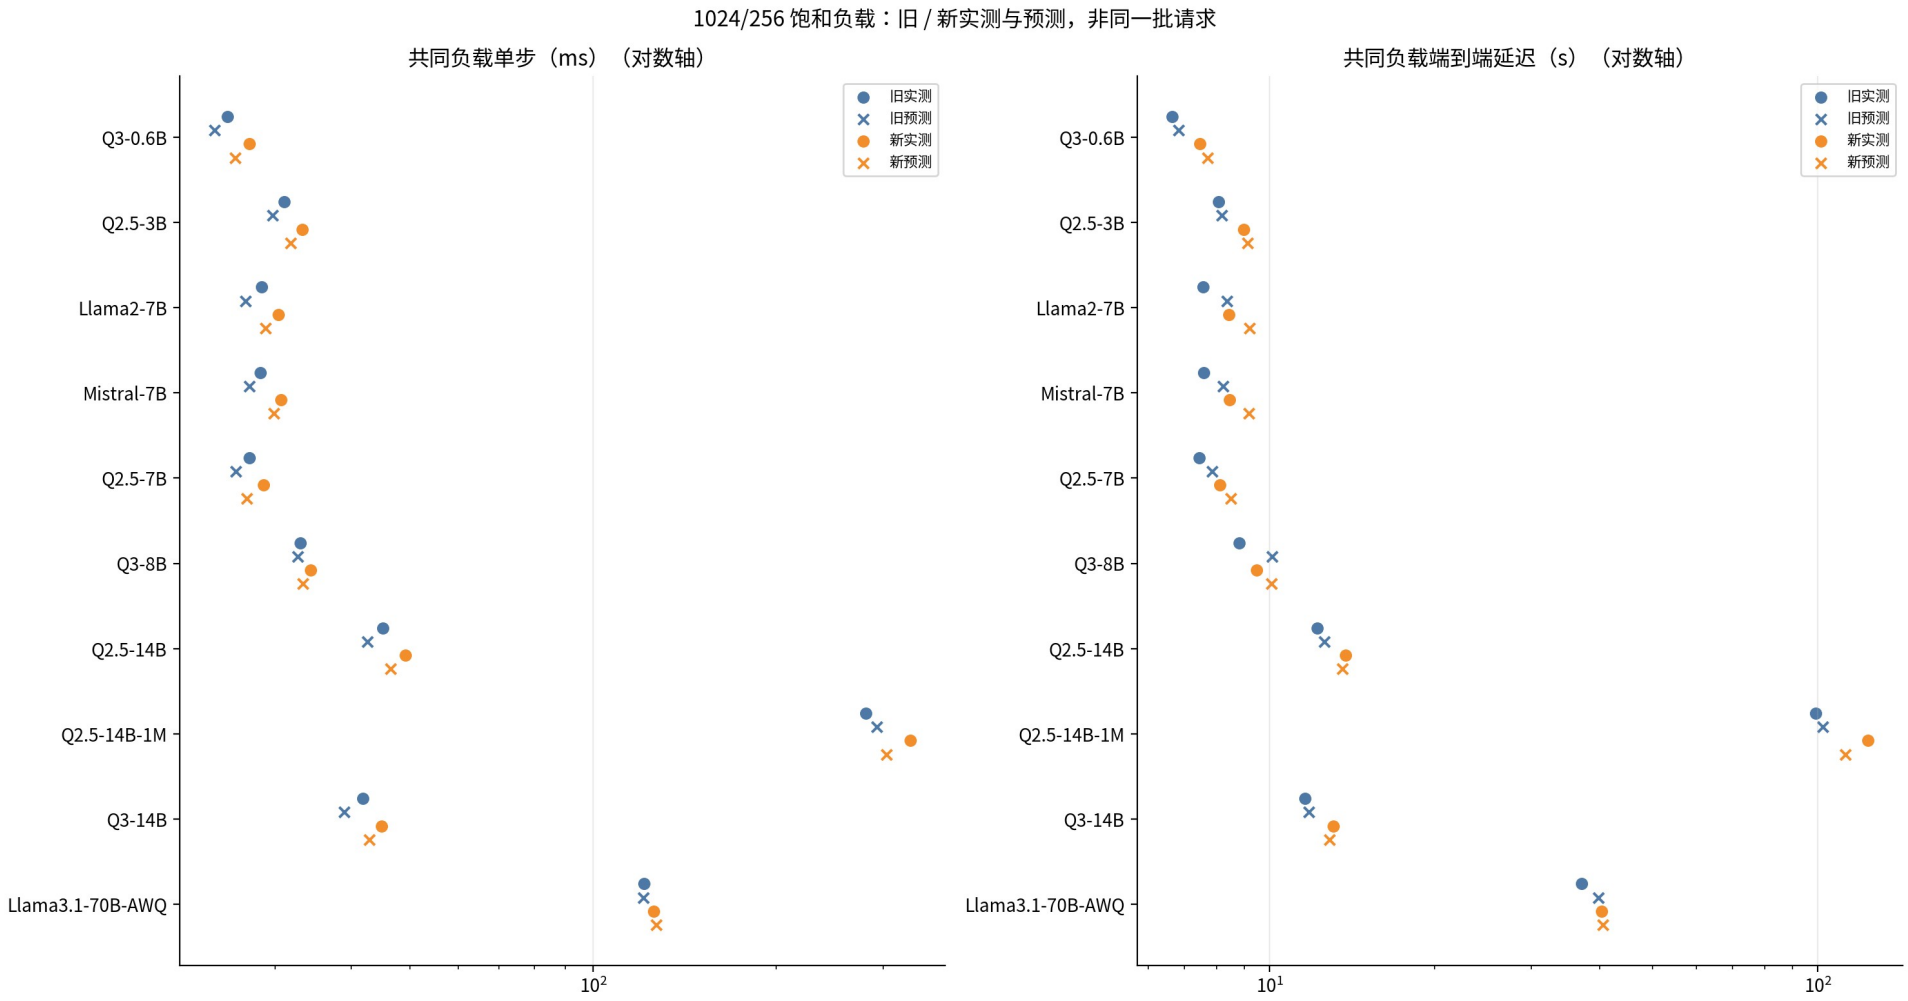
6.2 端到端实测、预测与误差

模型	旧实测（s）	旧预测（s）	旧 MAPE	本轮实测（s）	本轮预测（s）	本轮 MAPE	变化（百分点）
Q3-0.6B	6.639	6.823	3.09%	7.461	7.714	6.43%	3.346
Q2.5-3B	8.060	8.181	3.33%	8.969	9.110	4.10%	0.775
Llama2-7B	7.559	8.364	10.58%	8.430	9.180	8.94%	-1.641
Mistral-7B	7.586	8.223	8.37%	8.444	9.161	8.63%	0.251
Q2.5-7B	7.440	7.864	5.79%	8.122	8.504	5.97%	0.178
Q3-8B	8.795	10.116	14.85%	9.471	10.080	6.43%	-8.422
Q2.5-14B	12.213	12.589	3.25%	13.752	13.563	3.80%	0.552
Q2.5-14B-1M	99.032	102.279	3.29%	123.490	112.448	9.71%	6.420
Q3-14B	11.593	11.791	2.10%	13.085	12.851	5.09%	2.980
Llama3.1-70B-AWQ	37.096	39.784	7.16%	40.382	40.540	0.84%	-6.321

相同负载设置下，旧与新 ML 的误差比较



相同负载设置下，旧与新实测值、预测值比较



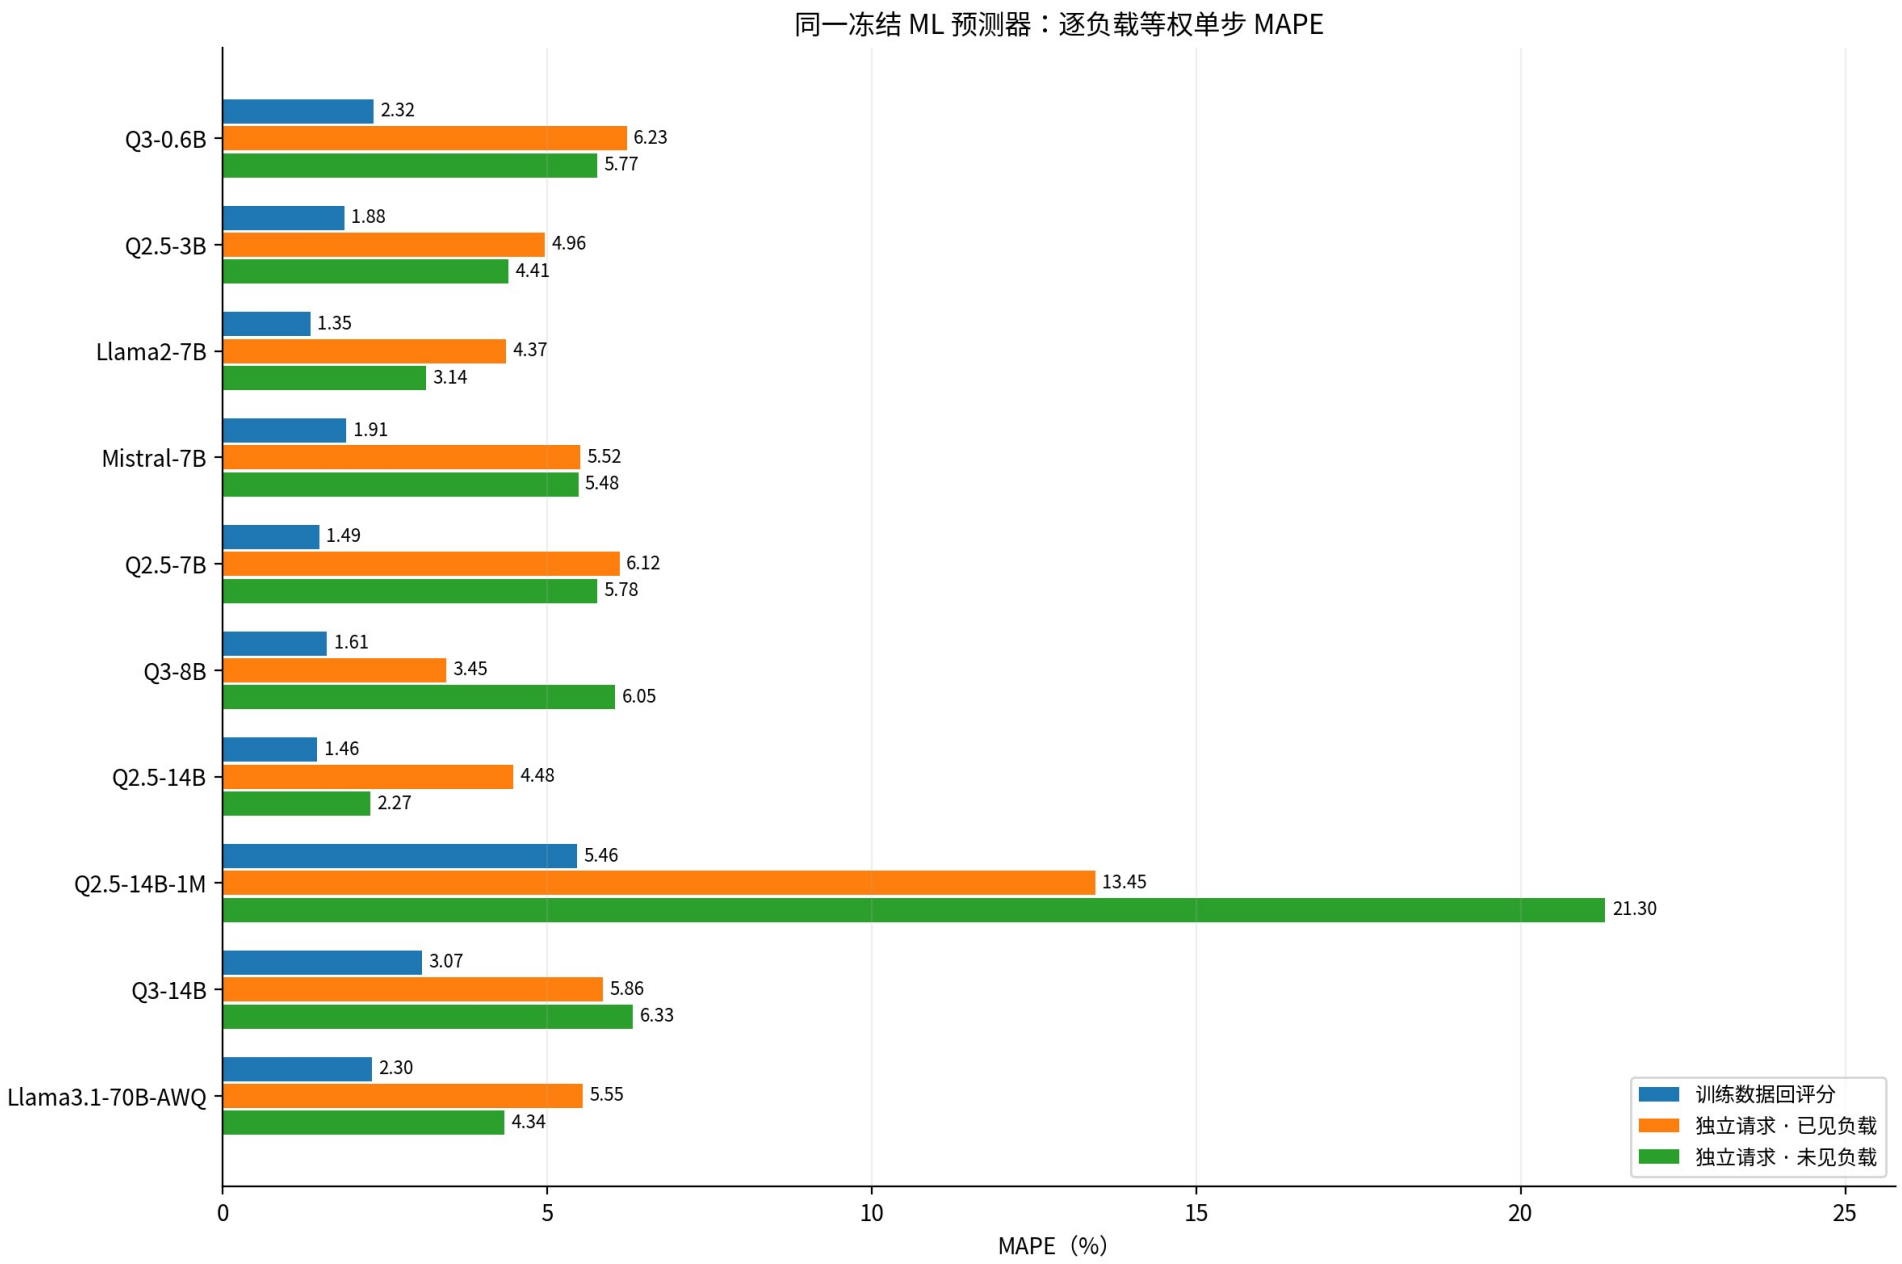
共同负载单步误差下降的模型为 Q3-8B、Q3-14B、Llama3.1-70B-AWQ（3/10）；E2E 误差下降的是 Llama2-7B、Q3-8B、Llama3.1-70B-AWQ（3/10）。采样量增加后，误差并未在所有模型上同步下降。

7. 同一预测器：训练数据与独立请求

各行使用同一个已冻结的本轮预测器，不重新训练。三个阶段按负载等权汇总单步 MAPE，因此与第 3 节按 batch 数加权的总体 MAPE 不同。训练回评分不是独立测试；未见负载为短延迟、长饱和两类。

模型	训练回评分	独立请求：已见负载	独立请求：未见负载	已见负载增量（百分点）	未见负载增量（百分点）
Q3-0.6B	2.32%	6.23%	5.77%	3.905	3.450
Q2.5-3B	1.88%	4.96%	4.41%	3.081	2.526
Llama2-7B	1.35%	4.37%	3.14%	3.015	1.785
Mistral-7B	1.91%	5.52%	5.48%	3.611	3.574
Q2.5-7B	1.49%	6.12%	5.78%	4.630	4.288
Q3-8B	1.61%	3.45%	6.05%	1.837	4.438
Q2.5-14B	1.46%	4.48%	2.27%	3.017	0.814
Q2.5-14B-1M	5.46%	13.45%	21.30%	7.987	15.844
Q3-14B	3.07%	5.86%	6.33%	2.795	3.256
Llama3.1-70B-AWQ	2.30%	5.55%	4.34%	3.249	2.045

同一冻结预测器的训练回评分与独立请求误差



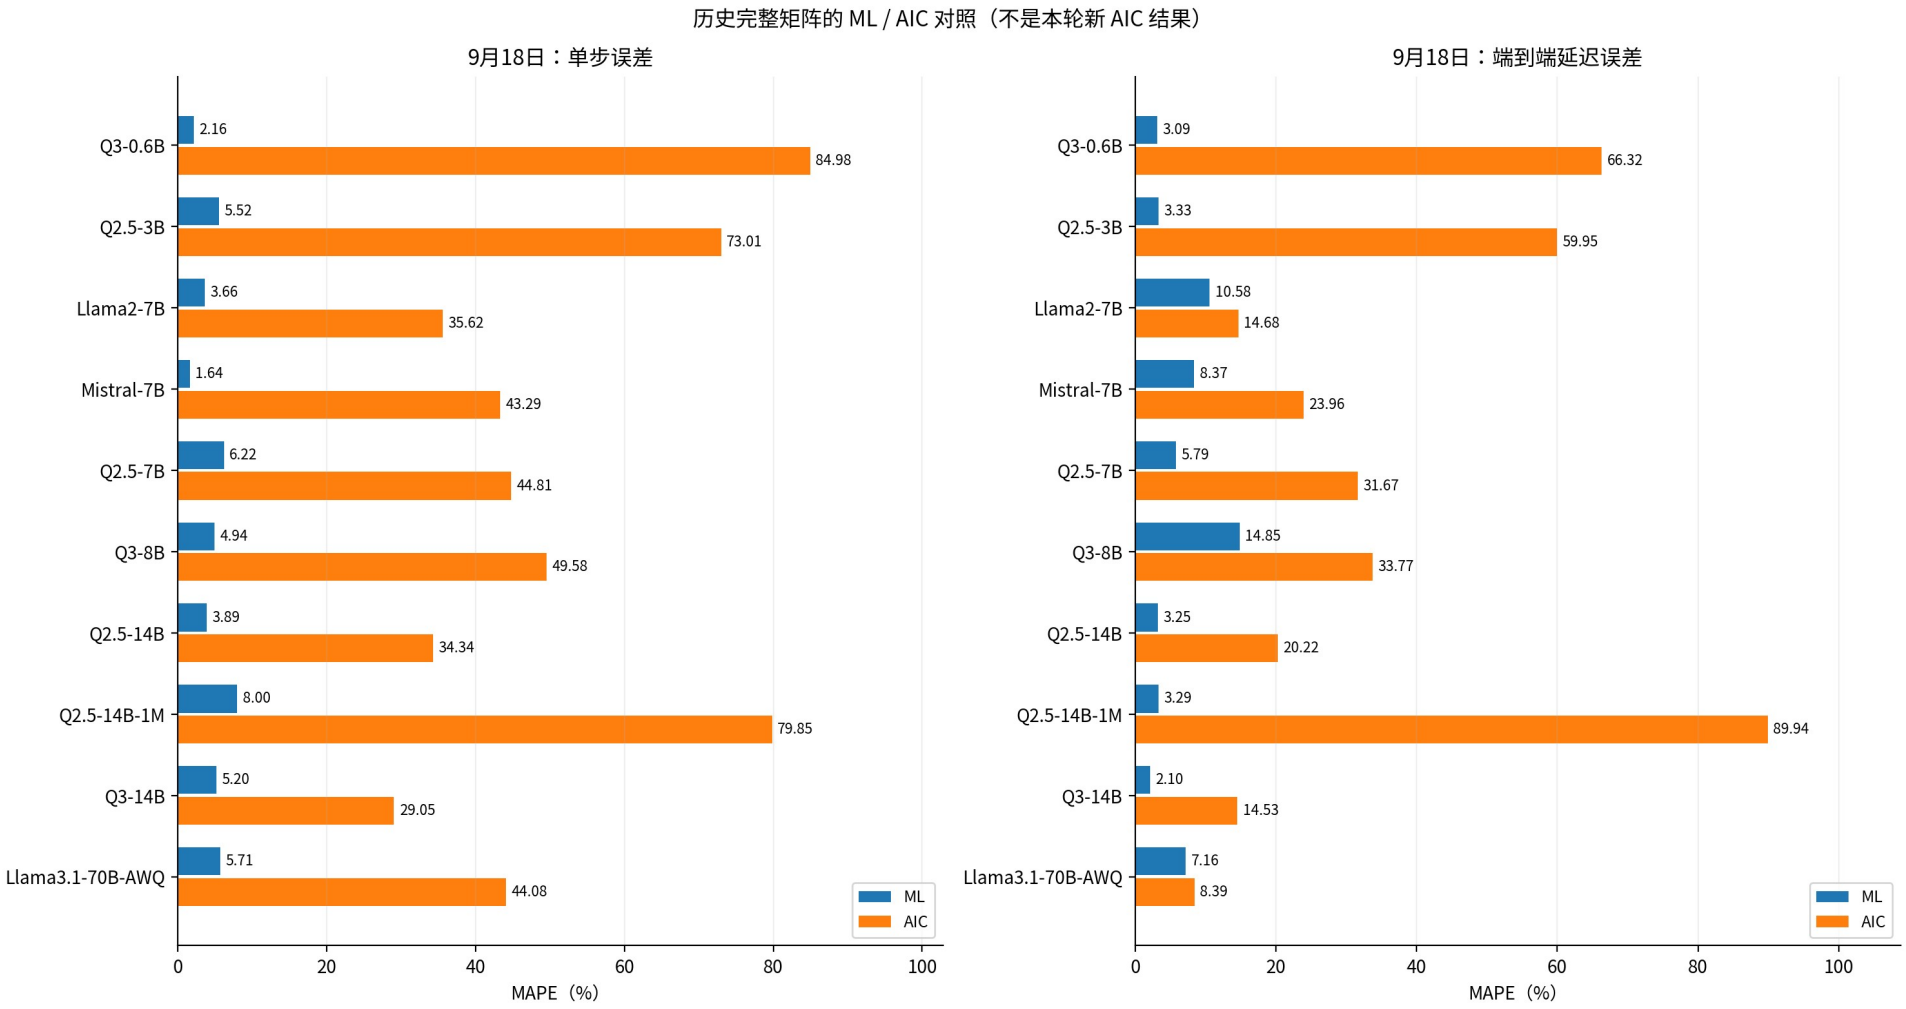
独立请求误差普遍高于训练回评分。除 14B-1M 外，已见负载独立测试的等权 MAPE 为 3.45%—6.23%；14B-1M 为 13.45%，未见负载为 21.30%。这组比较同时包含请求内容、batch 分布和采集时间的变化，不将差异全部归因于文本内容。

8. 历史 AIC 对照

以下仅为 9 月 18 日已完成实验，负载仍是 1024/256 饱和。本轮新 AIC 结果尚未形成，不能把这张表当作本轮采样后的 AIC 精度。14B-1M、70B-AWQ 的历史 AIC 使用代理算子配置，不是原生 DCA、INT4 Marlin 的精确对应。

模型	AIC 单步实测 / 预测（ms）	单步 MAPE	AIC E2E 实测 / 预测（s）	E2E MAPE
Q3-0.6B	25.04 / 3.58	84.98%	6.639 / 2.232	66.32%
Q2.5-3B	31.05 / 8.03	73.01%	8.060 / 3.222	59.95%
Llama2-7B	28.47 / 18.05	35.62%	7.559 / 6.455	14.68%
Mistral-7B	28.34 / 16.25	43.29%	7.586 / 5.764	23.96%
Q2.5-7B	27.19 / 15.14	44.81%	7.440 / 5.090	31.67%
Q3-8B	33.00 / 16.70	49.58%	8.795 / 5.811	33.77%
Q2.5-14B	45.12 / 30.25	34.34%	12.213 / 9.744	20.22%
Q2.5-14B-1M	280.96 / 29.99	79.85%	99.032 / 9.973	89.94%
Q3-14B	41.83 / 30.32	29.05%	11.593 / 9.886	14.53%
Llama3.1-70B-AWQ	121.06 / 137.83	44.08%	37.096 / 40.235	8.39%

9 月 18 日完整实验中的 ML 与 AIC 误差



9. 阶段总结

- 10 个 dense checkpoint 的本轮 ML 结果已齐全。总体单步 MAPE 为 3.52%—12.18%，E2E MAPE 为 3.18%—12.02%；两种统计分别采用 batch 加权和用例等权。
- 共同饱和负载下，单步和 E2E 均只有 3/10 个模型较 9 月 18 日误差下降。当前不能得出“多采样一定更准”的结论。
- 14B-1M 的短负载单步误差和 70B-AWQ 的 TPOT 误差仍需关注；不能只以整体 E2E 判断各阶段预测是否准确。
- 本报告不包含尚未完成的 32B 和本轮新 AIC 对照。旧 AIC 结果仅保留作历史参考。

数据来源

本轮目录：test-results/pr33824_expanded_all13_predictors_20260928_1933；历史目录：test-results/pr33824_comprehensive_all13_predictors_20260918_1605。每模型的 holdout/ml_teacher_forced/、holdout/ml_e2e_comparison/ 保存逐 batch 与逐用例结果；历史 AIC 对应 aic_teacher_forced/、aic_e2e_comparison/。

本报告的冻结数据快照 (../test-results/pr33824_expanded_all13_predictors_20260928_1933/reports/dense_stage_20260929_1906/summary.json)、共同负载比较 CSV (../test-results/pr33824_expanded_all13_predictors_20260928_1933/reports/dense_stage_20260929_1906/matched_workload_comparison.csv)、单步汇总 CSV (../test-results/pr33824_expanded_all13_predictors_20260928_1933/reports/dense_stage_20260929_1906/current_single_step.csv)和六张图保存在同一个阶段目录。生成时重算并核对保存的逐行误差与汇总，1540 个被读取的来源文件哈希前后未变；未新增 GPU 实验、训练或预测查询。